# TAGNE DONALD


01788195598

donaldtagne516@gmail.com

Carl-Schurz.Straße 3, 67549 Worms

1999-01-03

Kamerunisch

Klasse B

Ledig


## PROFESSIONAL SUMMARY

AI Solutions Specialist mit starkem technischem Hintergrund und Erfahrung in der Konzeption, Entwicklung und Integration von KI-Lösungen mit Fokus auf Large Language Models und Generative AI. Ich verbinde Business Anforderungen mit technischer Umsetzung, identifiziere geeignete KI Use Cases und setze diese als skalierbare, produktionsreife Lösungen um. Mein Schwerpunkt liegt auf LLM-basierten Anwendungen wie Retrieval-Augmented Generation, AI Agents und intelligenter Prozessautomatisierung, die messbaren Mehrwert für Unternehmen schaffen. Dabei bringe ich ein tiefes Verständnis für Daten, Modellarchitekturen und Cloud-Infrastrukturen (u. a. AWS) mit, ohne den Business-Impact aus dem Blick zu verlieren. Ich suche eine Vollzeitposition, in der ich als Schnittstelle zwischen Fachbereichen, Produkt und Engineering innovative KI-Lösungen gestalte und Unternehmen bei der erfolgreichen

## GITHUB, LINKEDIN, PORTFOLIO

- https://github.com/donaldtagne?tab=repositories
- https://www.linkedin.com/in/chris516/
- https://donaldtagne.netlify.app/

## BERUFSERFAHRUNG

07/2025 – 01/2026 *7 Monate*

**Masterand – GenAI & LLM Infrastructure**

**Randstad Digital** | Frankfurt, Eschborn

- Vergleich und Analyse von Cloud-RAG-, lokalen RAG- und Hybrid-RAG-Architekturen; Durchführung von Leistungs- und Kosten-Benchmarks zwischen Claude 3.5 Sonnet (AWS Bedrock) und Qwen3-235B (lokal via vLLM) mit Identifikation von bis zu 90 % Kosteneinsparung bei vergleichbarer Antwortqualität.
- Entwicklung produktionsreifer RAG-Chatbots mit React.js-Frontend (TypeScript) auf Basis von LangChain und LlamaIndex; Integration von Model Context Protocol (MCP) und ConversationSummaryMemory für zuverlässiges, zustandsbehaftetes Tool-Calling und effizientes Langzeit-Kontextmanagement.
- Einsatz von Streamlit für schnelles Prototyping, interne Tests und Stakeholder-Demos zur Ermöglichung kurzer Iterationszyklen und schneller Feedback-Schleifen in der Entwicklungsphase.

Einführung von Generative AI unterstütze.

## QUALIFICATIONS AND SKILLS

- LLMs (claude , Gemini, Copilot, Chatgpt)
- RAG(Retrieval Augmented Generation)
- MCP(Model Context Protocol)
- Langchain
- LlamaIndex
- AWS Bedrock
- Ollama & OpenWebui
- Vektordatenbank(Chroma, FAISS, Pinecone)
- Speech AI (Whisper AI)
- RAGAS
- NLP
- SLMs-finetuning
- Multi-Modal RAG
- Huggingface
- Llama.cpp
- Hybrid-RAG
- Autogen
- MemO
- Composio
- Kotlin
- C++/C#/Python
- Java
- SQL
- MariaDB
- Flutter
- REST
- GraphQL
- Scrum
- Docker
- Podman
- Oracle Developer
- Pytorch

- Implementierung von PDF-Ingestion-Pipelines mit fortgeschrittenem Chunking und Vektorisierung auf Basis von FAISS und Chroma; schnelles Deployment über Streamlit Community Cloud, Docker und ngrok für interne Demos und Stakeholder-Tests.
- Evaluierung von RAG-Systemen mit RAGAS und benutzerdefinierten Metriken (Latenz, Kosten pro Query, DSGVO-Score) sowie Durchführung von Load- und Stresstests mit Locust.
- Anwendung von Advanced Prompting-Techniken (Chain-of-Thought, Few-Shot, Self-Consistency) und Guardrails zur Steigerung von Genauigkeit, Robustheit und Compliance der GenAI-Anwendungen.
- Nutzung von AWS EC2 GPU-Instanzen (g5/p5) und Boto3-Skripting zur Automatisierung von Benchmarks sowie zum Monitoring und Tracking von Infrastruktur- und Modellkosten.
- Aufbau von Python-basierten ETL-Pipelines zur kontinuierlichen Datenaktualisierung in KI- und RAG-Workflows.

04/2025 – 09/2025 *6 Monate*

**Werkstudent-GenAI & Agentic AI Engineering**

**Abbvie** | Ludwigshafen

- Entwicklung und Deployment von Multi-Agent-Systemen mit AutoGen und CrewAI für autonome Workflows, kollaboratives Reasoning und toolgestützte Entscheidungslogik im Kontext von GenAI- und Agentic-AI-Anwendungen.
- Implementierung persistenter Memory-Layer mit MemO sowie Integration von Tools über Composio zur Anbindung externer APIs (GitHub, Datenbank) für kontextbewusste Agenten-Interaktionen.
- Konzeption und Umsetzung agentischer Orchestrierungsmuster (Planner–Executor–Critic, Multi-Role Agents, Reflection Loops) zur Strukturierung komplexer Aufgabenketten.
- Integration verschiedener LLMs in hybride Setups (OpenAI, Claude via Bedrock/API, Llama 3, Mistral Large) zur Definition spezialisierter Agenten-Rollen und Modellselektion je Use Case.
- Implementierung von Retrieval-augmented Agents mit Vektor-Datenbanken (FAISS, Chroma) zur Kombination von RAG-Ansätzen mit agentenbasiertem Planning.
- Nutzung von Inference-Backends wie vLLM und Ollama zur skalierbaren sowie lokalen Ausführung von Agenten für unterschiedliche Umgebungen.
- Durchführung von Observability- und Evaluationsmaßnahmen mit LangSmith (Tracing) und DeepEval (Faithfulness, Accuracy, Bias-Detection) zur Qualitäts- und Zuverlässigkeitsprüfung der Agenten.
- Entwicklung schneller Prototypen und interner Demos mit Streamlit und ngrok zur Validierung von GenAI- und Agentic-AI-Konzepten mit Stakeholdern.

- CI/CD
- Undefined

## BENUTZERDEFINIERT

- Basketball spielen
- Kochen
- Lesen
- Sport treiben

01/2024 – 03/2024 *3 Monate*

**Praktikant – Applied Generative AI**

**Fraunhofer-Zentrum** | Kaiserlautern

- Systematischer Vergleich von Small Language Models (SLMs) wie Gemma 2B und Qwen2 7B mit Large Language Models (LLMs) wie GPT 3-, Gemini und Claude hinsichtlich Kosten, Latenz, Kontextlänge, Reasoning-Fähigkeit und Produktionsreife zur Identifikation geeigneter Modelle für Applied-GenAI-Use-Cases.
- Implementierung und Analyse von Transformer-Architekturen mit Hugging Face zur Vertiefung des Verständnisses von Attention-Mechanismen, Tokenisierung und Kontextverarbeitung im Hinblick auf robuste, produktionsnahe GenAI-Anwendungen.
- Deployment lokaler Modelle mit Ollama sowie Optimierung der High-Throughput-Inferenz zur effizienten Skalierung generativer KI-Workloads.
- Aufbau von Vektordaten-Pipelines zur Generierung, Speicherung und Retrieval von Embeddings zur Verbesserung semantischer Suche und zur Entwicklung leistungsfähiger RAG-Systeme für applied Generative-AI-Szenarien.

02/2023 – 05/2024 *1 Jahr und 4 Monate*

**Werkstudent-Python Dev**

**Sparkassenversicherung** | Mannheim

- Entwicklung grafischer Benutzeroberflächen (GUI) in Python mit Tkinter und CustomTkinter zur Unterstützung interner Anwendungen.
- Automatisierung, Optimierung und Generierung von Testfällen in Python zur Verbesserung der Testabdeckung und -effizienz.
- Datenverarbeitung, -bereinigung und Analyse mit Pandas zur Auswertung und Aufbereitung relevanter Daten.
- Integration und Abfrage von Datenbanken mit Oracle SQL Developer zur Sicherstellung konsistenter Datenflüsse.
- Erstellung und Durchführung von Unit-Tests zur Gewährleistung von Funktionalität, Stabilität und Zuverlässigkeit der Anwendungen.
- Nutzung von Werkzeugen wie Gitea und Eclipse zur versionskontrollierten und strukturierten Softwareentwicklung.
- Einsatz von Python für Excel zur automatisierten Verarbeitung und Auswertung von Excel-Daten.
- Verwendung von Docker und Podman zur Bereitstellung und Ausführung von Anwendungen in isolierten Umgebungen.
- Arbeit mit Oracle Developer zur Unterstützung der datenbanknahen Entwicklung und Analyse.

05/2022 – 10/2022 *6 Monate*

**Werkstudent-Mobile-Dev**

**Engenious** | Brühl

- Objektorientierte Programmierung in C# mit Klassen, Methoden und Polymorphismus zur strukturierten und wartbaren Codeentwicklung.
- Mobile Entwicklung mit Xamarin, inklusive Gestaltung von Benutzeroberflächen, Eventhandling und Implementierung der zugrunde liegenden Modelle.
- Konzeption und Umsetzung eines Analysetools für Rechnungen auf Basis von UML-Diagrammen, C#-Implementierung und Anbindung an eine Excel-Verarbeitungsschnittstelle.

## EDUCATION

01/2025

**Hochschule Worms** | Worms

Master of Science: Ang Informatik mit Schwerpunkt Cloud Computing/ AI

09/2023

**Hochschule Worms** | Worms

Bachelor of Science: Angewandte Informatik mit Schwerpunkt Software Entwicklung

## SPRACHEN

**Deutsch** C2

Annähernd muttersprachliche Kenntnisse

**Französisch** C2

Annähernd muttersprachliche Kenntnisse

**Englisch** A2

Grundlegende Kenntnisse